

Tugas Besar

Proyek Analisis Dataset dan Penerapan Algoritma Machine Learning

DESKRIPSI

Tugas besar ini bertujuan memberikan pengalaman *end-to-end* dalam menyelesaikan permasalahan data menggunakan pendekatan *Machine Learning*. Mahasiswa bekerja dalam kelompok untuk mencari dataset secara mandiri, melakukan eksplorasi data, membangun model *machine learning*, melakukan evaluasi, *tuning parameter*, dan menarik *insight* yang bernilai dari hasil analisis.

Mahasiswa diharapkan tidak hanya mampu menjalankan algoritma, tetapi juga memahami mengapa model tertentu dipilih, bagaimana meningkatkan performa model, dan apa makna hasil model terhadap masalah nyata.

Ketentuan Kelompok

- 1 kelompok terdiri dari maks. **3 orang**
- Setiap kelompok wajib memiliki kontribusi anggota yang seimbang
- Tidak diperbolehkan menggunakan dataset yang sama persis dengan kelompok lain (kecuali topik berbeda dan disetujui dosen)

Tema Dataset

Dataset bebas, dapat berasal dari berbagai domain, misalnya:

- Kesehatan
- Pendidikan
- Finansial
- Penjualan / Bisnis
- Sosial Media
- Transportasi
- Olahraga
- Cuaca
- Pertanian
- Customer Behavior
- Human Resources
- E-commerce

Sumber dataset dapat berasal dari:

- Kaggle
- UCI Machine Learning Repository
- [Data.go.id](https://data.go.id)
- World Bank Data
- Google Dataset Search
- Dataset publik lainnya

Tujuan Proyek

Setiap kelompok harus mampu menjawab pertanyaan berikut:

1. Masalah apa yang ingin diselesaikan?
2. Mengapa *dataset* tersebut menarik / penting?
3. *Insight* apa yang bisa diperoleh?
4. Algoritma *machine learning* apa yang cocok?
5. Seberapa baik performa model?
6. Bagaimana meningkatkan performa model melalui *hyperparameter tuning*?
7. Kesimpulan apa yang dapat diambil?

Tahapan Pengerjaan

1. Pemilihan Dataset

- Pilih *dataset* yang memiliki jumlah data memadai
- Jelaskan sumber *dataset*
- Jelaskan atribut/fitur yang tersedia
- Tentukan tujuan analisis

2. Data Understanding & Exploratory Data Analysis (EDA)

- Lakukan analisis awal: ukuran dataset, jumlah fitur, tipe data, *missing value*, *outlier*, distribusi data, korelasi antar variabel, visualisasi.
- Gunakan grafik seperti: *histogram*/ *boxplot*/ *heatmap*/ *bar chart*/ *scatter plot*

3. Data Preprocessing

Lakukan proses yang diperlukan, misalnya:

- *handling missing values*
- *encoding categorical data*
- *normalization* / *standardization*
- *feature selection*
- *balancing class* (jika data imbalance)
- *train-test split*

4. Penerapan Machine Learning

Gunakan **minimal 3 algoritma *machine learning***, misalnya:

1. **Classification:** Logistic Regression/ Decision Tree/ Random Forest/ KNN/ Naive Bayes/ SVM/ XGBoost
2. **Regression:** Linear Regression/ Decision Tree Regressor/ Random Forest Regressor/ SVR/ Gradient Boosting
3. **Clustering:** K-Means/ DBSCAN/ Hierarchical Clustering

(Pilih sesuai kasus dataset)

5. Evaluasi Model

Gunakan metrik yang sesuai:

- **Classification:** Accuracy/ Precision/ Recall/ F1-score/ ROC-AUC/ Confusion Matrix
- **Regression:** MAE/ MSE/ RMSE/ R^2 Score
- **Clustering:** Silhouette Score/ Davies-Bouldin Index

Bandingkan performa antar model.

6. Hyperparameter Tuning

Lakukan tuning pada minimal 1 model terbaik menggunakan: GridSearchCV/ RandomizedSearchCV/ Bayesian Optimization (opsional). Contoh parameter:

- KNN: k
- Random Forest: n_estimators, max_depth
- SVM: C, kernel, gamma
- XGBoost: learning_rate, max_depth

Bandingkan performa sebelum dan sesudah tuning.

7. Insight dan Interpretasi

Tuliskan *insight* yang diperoleh, contoh:

- faktor paling berpengaruh terhadap *churn* pelanggan
- prediktor utama harga rumah
- pola pelanggan berisiko gagal bayar
- segmentasi pelanggan
- fitur paling penting dalam prediksi penyakit
- produk paling favorit di pasaran

8. Kesimpulan

Berisi:

- model terbaik
- performa akhir
- *insight* utama

- kendala penelitian
- saran pengembangan lanjutan

Output yang Dikumpulkan

1. Laporan (PDF):

Format isi:

1. Cover
2. Anggota kelompok
3. Pendahuluan
4. Dataset
5. Metodologi
6. EDA
7. Modeling
8. Hyperparameter Tuning
9. Insight
10. Kesimpulan
11. Referensi

Minimal 10 halaman.

2. Source Code: Notebook Python (.ipynb) atau .py

3. Slide Presentasi: 8–12 slide

4. Presentasi:

Durasi:

Presentasi: 10 menit

Tanya jawab: 5 menit

Setiap anggota wajib presentasi.

Kriteria Penilaian (100%)

Komponen	Bobot
Pemilihan masalah & dataset	10%
EDA & preprocessing	15%
Implementasi model	20%
Evaluasi model	15%
Hyperparameter tuning	15%
Insight & interpretasi	15%
Presentasi & komunikasi	10%

Catatan Penting

- Tidak melakukan plagiarisme
- Wajib memahami seluruh kode yang dibuat
- Boleh menggunakan library Python (Scikit-learn, Pandas, XGBoost, dll)

Bonus Nilai

Diberikan jika membuat:

- *Dashboard* interaktif
- *Deployment* model sederhana
- *Web app demo*